

Data Analyse Agent

综合测试卷（一）：项目架构与数据管理

基础理解、目录结构、数据持久化、数据库服务与 API

项目名称	Data Analyse Agent
总分	100 分
题型	填空题 40 分；简答题与分析题 60 分
考查重点	项目目标、数据生命周期、SQLite、Manifest、关系配置、API 与评测入口
版本说明	依据当前项目代码、README、evals、tests 与实现说明生成

使用说明：本 PDF 为“题目 + 标准答案 + 详细解析”的完整复习版。每题均标注项目知识点或代码位置，便于回到源码中复盘。

目录与分值校验

一、填空题：20 道，每题 2 分，共 40 分。

二、简答题与分析题：10 道，每题 6 分，共 60 分。

总分校验：40 + 60 = 100 分。

部分	题量	单题分值	小计
填空题	20	2 分	40 分
简答题与分析题	10	6 分	60 分
合计	30	-	100 分

覆盖范围：项目背景、目录结构、数据集持久化、Manifest、SQLite、关系配置、API、ScopeRouter、Planner、工具策略、Python 沙箱、Artifact Store、上下文压缩、前端 SSE 展示、自动化评测与优化方向。

第一部分：填空题（共 40 分）

1. 题目（2 分）：本项目的后端 Web 框架是 _____，浏览器前端由后端直接托管，不需要单独运行 Node 开发服务器。

标准答案

FastAPI

详细解析

README 的技术栈和启动说明明确写出后端使用 FastAPI、Uvicorn，前端是原生 HTML/CSS/JavaScript 并由 FastAPI 直接提供。理解这一点能区分本项目和前后端分离构建项目。

对应项目知识点或代码位置：README.md：技术栈、启动项目。

2. 题目（2 分）：每个上传数据集都会生成一个独立的 SQLite 数据库文件，文件名是 _____。

标准答案

dataset.sqlite3

详细解析

DatasetService 中 SQLITE_FILENAME = "dataset.sqlite3"，README 本地存储结构也列出每个 dataset_id 目录下保存该文件。

对应项目知识点或代码位置：app/services/dataset_service.py；README.md：本地存储。

3. 题目（2 分）：上传的原始文件保存在 _____ 目录，系统设计要求它们永不被修改。

标准答案

raw/

详细解析

项目采用 raw 与 processed 分层：raw 保存原始 CSV/Excel，processed 保存当前可被清洗和重建 SQLite 的数据。清洗只影响 processed。

对应项目知识点或代码位置：README.md：当前功能、本地存储；app/services/preprocessing_service.py。

4. 题目（2 分）：每张逻辑表当前版本的数据保存在 _____ 目录，并会被清洗工具更新。

标准答案

processed/

详细解析

PreprocessingService 调用 DatasetService.replace_processed_tables 更新 processed 数据，并重建 SQLite。raw_unchanged=True 是返回结果中的关键保证。

对应项目知识点或代码位置：README.md：本地存储；app/services/preprocessing_service.py。

5. 题目（2 分）：记录字段统计、清洗历史、主外键和索引配置的标准文件是 _____。

标准答案

manifest.json

详细解析

README 明确说明每个数据集包含 manifest.json。PreprocessingService 在清洗后读取并写回 Manifest，记录 cleaning_steps 和 processing_status。

对应项目知识点或代码位置：README.md：当前功能、本地存储；app/schemas/manifest.py。

6. 题目（2 分）：单表数据集通过 SQLite 视图兼容的默认别名是 _____。

标准答案

data_table

详细解析

README 的使用界面部分说明单表可使用 data_table，多表必须使用 schema 中具体表名。DatasetService 中也有 DEFAULT_SINGLE_TABLE_ALIAS = "data_table"。

对应项目知识点或代码位置：README.md：使用界面；app/services/dataset_service.py。

7. 题目（2 分）：上传或追加数据后，项目会自动分析主键、外键和索引候选，并由 _____ 给出受候选集约束的推荐。

标准答案

LLM

详细解析

README 当前功能说明关系配置由统计候选和 LLM 推荐组成；但 LLM 只能在候选集合内推荐，业务语义仍需用户确认。

对应项目知识点或代码位置：README.md：当前功能、当前限制；app/services/relationship_service.py。

8. 题目（2 分）：用户必须确认一次关系配置后才能使用 Agent，这一检查发生在聊天请求的 _resolve_conversation 中，会调用 _____。

标准答案

dataset_service.require_relationship_configuration(dataset_id)

详细解析

app/api/chat.py 的 _resolve_conversation 在已有 conversation 和新 dataset 两种路径都会调用该方法，保证未确认关系的数据集不能直接进入 Agent。

对应项目知识点或代码位置：app/api/chat.py：_resolve_conversation。

9. 题目（2 分）：本项目用于执行只读 SQL 查询的服务类是 _____。

标准答案

SQLService

详细解析

SQLService 封装 SQLite 只读 URI、query_only、authorizer、超时和行数上限，是 query_data、generate_chart、python_analysis 的基础数据入口。

对应项目知识点或代码位置：app/services/sql_service.py；app/agent/tools.py。

10. 题目（2 分）：SQLService 只允许以 _____ 或 _____ 开头的单条查询。

标准答案

SELECT；WITH

详细解析

_validate_sql 检查 normalized SQL 必须 startswith select 或 with，并禁止一条语句中包含额外分号。

对应项目知识点或代码位置：app/services/sql_service.py：_validate_sql。

11. 题目（2 分）：图表生成后的 PNG 文件默认保存在 app/storage/_____ 目录，并通过 /charts/{chart_id}.png 访问。

标准答案

charts

详细解析

ChartService 生成 PNG 到 app/storage/charts，README 的 API 部分说明图表通过 /charts/{chart_id}.png 访问。

对应项目知识点或代码位置：app/services/chart_service.py；README.md：API。

12. 题目（2 分）：负责创建、读取、保存对话 JSON，并支持恢复历史对话的服务是 _____。

标准答案

ConversationService

详细解析

chat.py 通过 conversation_service append_message/append_messages 保存用户消息、工具事件、plan、scope、artifact 和 assistant 文本。

对应项目知识点或代码位置：app/services/conversation_service.py；app/api/chat.py。

13. 题目（2 分）：上下文窗口默认限制常量是 _____ tokens，达到阈值后会压缩早期对话。

标准答案

24000

详细解析

ContextService 中 DEFAULT_CONTEXT_LIMIT_TOKENS = 24000，压缩阈值默认是 0.8。前端侧栏展示 token 估算。

对应项目知识点或代码位置：app/services/context_service.py；frontend/index.html。

14. 题目（2 分）：项目的自动化评测流水线入口脚本位于 _____。

标准答案

evals/runners/run_evals.py

详细解析

最近新增的 evals 目录包含 cases、runner 和 reports。runner 会生成临时电商 fixture 数据集并输出 latest.json。

对应项目知识点或代码位置：evals/README.md；evals/runners/run_evals.py。

15. 题目（2 分）：项目用于启动 Web 服务的入口脚本是 _____。

标准答案

run.py

详细解析

README 启动项目部分给出的命令是 python run.py。该脚本启动 Uvicorn，并默认开启自动重载。

对应项目知识点或代码位置：README.md：启动项目；run.py。

16. 题目（2 分）：项目的 Python 包配置文件是 _____，其中也配置了 pytest 的测试路径。

标准答案

pyproject.toml

详细解析

pyproject.toml 是现代 Python 项目配置入口，README 和测试输出都显示 rootdir/configfile 指向该文件。

对应项目知识点或代码位置：pyproject.toml；pytest 输出。

17. 题目（2 分）：上传文件大小限制可通过环境变量 _____ 配置，留空或 0 表示不设置应用层上传大小限制。

标准答案

DATA_ANALYSE_MAX_UPLOAD_MB

详细解析

README 的 .env 示例中说明该变量；DatasetService 的 get_upload_size_limit_bytes 会读取并解析它。

对应项目知识点或代码位置：README.md：配置模型；app/services/dataset_service.py。

18. 题目（2 分）：用于把旧数据集补建 SQLite 文件并检查表行数的脚本是 _____。

标准答案

scripts/materialize_sqlite.py

详细解析

README 测试和诊断部分说明 materialize_sqlite.py 可为旧数据集生成缺失 SQLite，并支持 --rebuild。

对应项目知识点或代码位置：README.md：测试和诊断；scripts/materialize_sqlite.py。

19. 题目（2 分）：本项目自动测试命令是 _____，当前测试覆盖 SQL、Planner、ScopeRouter、Python 沙箱、Artifact Store 等模块。

[标准答案](#)

python -m pytest

[详细解析](#)

README 测试部分给出该命令，测试目录中包含 test_sql_service.py、test_planner_policy.py、test_artifact_store.py 等。

对应项目知识点或代码位置：README.md：测试和诊断；tests/。

20. 题目（2 分）：当前项目没有用户认证和权限隔离，因此定位是 _____ 环境。

[标准答案](#)

本地单用户开发与实验

[详细解析](#)

README 当前限制明确说明项目没有用户认证和权限隔离，定位为本地单用户开发与实验环境。该点关系到安全边界判断。

对应项目知识点或代码位置：README.md：当前限制。

第二部分：简答题与分析题（共 60 分）

1. 题目（6

分）：说明本项目为什么适合作为“数据库系统原理”课程设计，而不仅是一个普通聊天应用。

标准答案

参考答案：项目围绕结构化数据管理展开，包含 CSV/Excel 上传、表名规范化、Manifest 元数据、SQLite 建库、主外键和索引配置、只读 SQL 查询、多表 JOIN、清洗后重建数据库、关系完整性验证和查询安全控制。Agent 只是交互层，核心数据仍由 SQLite、schema、manifest 和服务层管理。

评分标准

- 指出结构化数据上传和 SQLite 建库 1.5 分
- 指出 Manifest、关系配置、主外键/索引 1.5 分
- 指出 SQLService 只读查询和 JOIN 能力 1 分
- 指出 Agent 是交互层而数据库服务是核心 1 分
- 结合课程目标说明价值 1 分

详细解析

关键在于把“自然语言分析”落到数据库对象与操作上：数据进入 raw/processed 分层，经过 DatasetService 写入 SQLite，再由 SQLService 和工具层查询。关系配置和索引让它不只是文件分析脚本。容易误解的是把项目看成 LLM demo；实际上 README 与服务层代码表明数据库建模、持久化、安全查询是主干。

对应项目知识点或代码位置：README.md；app/services/dataset_service.py；app/services/sql_service.py；app/services/relationship_service.py。

2. 题目（6 分）：梳理从上传多个 CSV/Excel 到可以被 Agent 查询的主要数据流。

标准答案

参考答案：上传请求进入 upload API，DatasetService 校验后创建 dataset_id 目录，保存 raw 文件并为每个逻辑表生成 processed CSV；随后重建 dataset.sqlite3，生成 schema 和 manifest，分析关系候选。用户确认关系后，SQLiteDDL/Storage 相关服务保存主外键和索引，Agent 读取 schema 并通过 SQLService 查询。

评分标准

- 上传 API 与 DatasetService 入口 1 分
- raw/processed 分层 1 分
- SQLite 重建与 schema/manifest 生成 1.5 分
- 关系配置确认 1 分
- Agent 通过 SQLService 使用数据库 1.5 分

详细解析

该流程体现数据从文件到数据库再到 Agent 的转换。Excel 多 Sheet 会变多张表，sanitize_table_name/unique_table_name 处理表名。Agent

不能在关系配置未确认时运行，因为 chat.py 会检查 require_relationship_configuration。

对应项目知识点或代码位置：app/api/upload.py；app/services/dataset_service.py；app/services/sqlite_storage_service.py；app/api/chat.py。

3. 题目（6 分）：分析 raw、processed、manifest、dataset.sqlite3 四者各自承担什么职责，以及为什么不能混为一谈。

标准答案

参考答案：raw 是不可变原始文件；processed 是当前可分析、可清洗的数据版本；manifest 记录字段、关系、索引和清洗历史等元数据；dataset.sqlite3 是供 SQL 查询和 Agent 使用的数据库物化结果。四者分离可支持回滚、重建、审计和课程中的数据一致性说明。

评分标准

- raw 不可变 1 分
- processed 是当前版本 1 分
- manifest 是元数据和历史 1.5 分
- SQLite 是查询物化层 1 分
- 说明分离带来的回滚/审计/重建价值 1.5 分

详细解析

如果直接修改 raw，会丢失原始依据；如果只有 SQLite，没有 processed 和 manifest，就难以追踪清洗历史与字段统计；如果只有 CSV，则 JOIN、索引和 SQL 安全查询能力不足。PreprocessingService 返回 raw_unchanged=True 正是设计意图。

对应项目知识点或代码位置：README.md：本地存储；app/services/preprocessing_service.py；app/schemas/manifest.py。

4. 题目（6 分）：解释为什么关系配置必须在使用 Agent 前完成。

标准答案

参考答案：关系配置让系统明确主键、外键和索引，提升 schema 可靠性，使 Agent 在多表 JOIN、字段引用和解释数据结构时有依据。chat.py 的 _resolve_conversation 会调用 dataset_service.require_relationship_configuration，未确认时拒绝进入 Agent。这样避免模型在关系不明确时胡乱 JOIN 或错误解释表关系。

评分标准

- 说明关系配置含主外键/索引 1.5 分
- 说明 chat.py 的强制检查 1.5 分
- 说明减少错误 JOIN 和误解释 1 分
- 说明用户确认和 LLM 推荐边界 1 分
- 分析便利性与可靠性的取舍 1 分

详细解析

关系配置并不等于 LLM 自动应用业务语义；README 限制说明 LLM 推荐仍需用户确认。该设计在工程上牺牲一些便利性，换来可解释、可控和课程答辩中更强的数据建模依据。

对应项目知识点或代码位置：app/api/chat.py：_resolve_conversation；README.md：当前功能、当前限制。

5. 题目（6分）：比较 /api/chat 与 /api/chat/stream 两条聊天接口的差异。

标准答案

参考答案：/api/chat 是非流式接口，保留旧的 LangGraph 工具循环；/api/chat/stream 是浏览器默认链路，接入 ScopeRouter + Plan-and-Execute，通过 SSE 返回 context、scope、plan、tool_start、tool_end、artifact、chart、text_delta 等事件，并保存更细粒度的历史消息。

评分标准

- 指出非流式 LangGraph 旧链路 1.5 分
- 指出流式 Plan-and-Execute 1.5 分
- 列出 SSE 事件或保存内容 1.5 分
- 说明前端默认使用流式 0.75 分
- 说明当前限制 0.75 分

详细解析

README 当前限制也说明 Plan-and-Execute 目前只接入流式接口。非流式接口仍能调用 ask_data_agent，但不会呈现 plan 面板和 step 状态。答题时不能把两条接口混为一谈。

对应项目知识点或代码位置：app/api/chat.py；app/agent/runtime.py；README.md：API、当前限制。

6. 题目（6分）：说明 SQLService 的安全机制，并分析它仍有哪些边界。

标准答案

参考答案：SQLService 通过只读 SQLite URI、PRAGMA query_only=ON、SQLite authorizer、禁止 DROP/DELETE/UPDATE/INSERT/PRAGMA 等关键字、单语句限制、超时中断和行数上限来控制风险。边界是这些是本地单用户应用层安全，不等同于公网多租户安全；复杂 SQL 资源消耗、业务权限、认证和审计仍需补充。

评分标准

- 只读 URI/query_only 1 分
- authorizer 1 分
- 关键字和单语句限制 1 分
- 超时和行数限制 1 分
- 指出安全边界不足 2 分

详细解析

安全机制分应用层和数据库层两类。_validate_sql 是应用层过滤，_authorize 是 SQLite 层拒绝写操作。README 明确说明 SQL 安全校验不应作为面向不可信公网用户的完整安全边界。

对应项目知识点或代码位置：app/services/sql_service.py；README.md：支持的 Agent 工具、当前限制。

7. 题目（6分）：如果用户删除数据集，为什么历史对话不会自动删除？这种设计有什么利弊？

标准答案

参考答案：README 明确说明删除数据集会删除其本地数据文件，但不会自动删除绑定该数据集的历史对话。优点是保留交互记录、答辩复盘和审计线索；缺点是对话再追问时可能因 dataset 不存在而无法继续执行，且需要 UI 或 API 提示数据缺失。

评分标准

- 说明 README 行为 1.5 分
- 说明对话和数据集分离 1 分
- 分析优点 1 分
- 分析缺点 1 分
- 提出改进 1.5 分

详细解析

这体现数据实体和对话实体分离。ConversationService 保存 JSON 历史，DatasetService 管理本地文件。更完善的设计可在对话列表标记“数据集已删除”，或提供级联删除选项。

对应项目知识点或代码位置：README.md：本地存储；app/services/conversation_service.py；app/services/dataset_service.py。

8. 题目（6 分）：解释为什么项目新增了自动化评测流水线，以及第一版评测覆盖了哪些层。

标准答案

参考答案：评测流水线用于把 ScopeRouter、Planner、Tool Routing、SQL、Python 沙箱等关键能力转成可重复验证的指标，支持课程答辩和复试展示。第一版在 evals/cases 中包含 scope_router、planner、tool_routing、sql_correctness、python_analysis，用 run_evals.py 生成临时电商数据集并输出 latest.json。

评分标准

- 说明评测目的 1.5 分
- 列出至少 4 类评测集 2 分
- 说明 runner 生成 fixture 和报告 1 分
- 说明对课程/复试价值 1 分
- 区分 pytest 与系统评测 0.5 分

详细解析

该流水线不是简单 pytest，而是面向系统能力的 benchmark 雏形。它把路由正确性、工具策略、SQL 执行安全、Python 静态安全和 Docker 冒烟分层，能暴露模型和工程逻辑问题。

对应项目知识点或代码位置：evals/README.md；evals/runners/run_evals.py；evals/cases/*.jsonl。

9. 题目（6 分）：从数据库课程角度，指出当前项目还可以补哪些内容来更贴近满分要求。

标准答案

参考答案：可补 ER 图和关系模式、范式分析、事务边界、清洗/重建 SQLite 的一致性策略、并发控制或 dataset-level lock、EXPLAIN QUERY PLAN 和索引性能对比、备份恢复策略、更多 SQL benchmark。

评分标准

- 提出建模/范式 1 分
- 提出事务/一致性 1.2 分
- 提出并发控制 1.2 分
- 提出查询计划/索引实验 1.4 分
- 明确这是优化方向而非已实现功能 1.2 分

详细解析

这些方向来自数据库系统原理核心主题。项目已有 SQLite、关系、索引和 SQL 安全，但事务、并发、优化器和恢复机制在 README 中还不是主线。不能虚构已实现的并发控制，应作为优化方向提出。

对应项目知识点或代码位置：README.md：当前限制；app/services/sqlite_storage_service.py；evals/README.md。

10. 题目（6 分）：设计一个针对本项目数据层的故障排查步骤：用户说“我上传了数据但 Agent 不能开始分析”。

标准答案

参考答案：先检查数据集是否创建成功和 metadata/manifest 是否存在；再确认 relationship_status 是否已确认；查看 dataset.sqlite3 是否生成；调用 GET /api/datasets/{dataset_id} 检查 schema；看 chat.py 返回是否来自 require_relationship_configuration；必要时运行 materialize_sqlite.py 或重新打开关系配置。

评分标准

- 检查数据集和 manifest 1 分
- 检查关系配置 1.5 分
- 检查 SQLite 文件 1 分
- 检查 schema/API 1 分
- 提出 materialize 或重配关系 1.5 分

详细解析

问题可能不在 LLM，而在数据生命周期。项目强制关系确认，并依赖 SQLite 物化数据库。排查要沿上传、manifest、关系配置、SQLite、聊天 API 逐层定位。

对应项目知识点或代码位置：app/api/chat.py；app/services/dataset_service.py；README.md：使用界面、测试和诊断。